Como escolhemos e avaliamos o SVM

Grid search e avaliação final walk-forward, explicados com exemplos reais do Bitcoin.

Grid search: qual configuração apresentou o melhor F1 na validação?
Avaliação final: como essa configuração se comportou nas datas posteriores?

O exemplo que vamos acompanhar

Moeda: **BTCUSDT**. Alvo: **2%**. Janela de treinamento: **60 observações diárias**. O mesmo raciocínio vale para as outras moedas, alvos de 3% e 4% e janelas de 75 e 90 observações.

O que uma linha de dados representa?

A linha tem as 22 features do dia **t**. Seu rótulo indica se, no dia **t+1**, a máxima atingiu pelo menos 2% acima da abertura. Se atingir, o alvo é 1; caso contrário, é 0.

Exemplo: abertura de 100 e máxima de 103 no dia seguinte produzem um movimento de 3%. O alvo de 2% recebe 1. Esse alvo usa a máxima intradiária, e não o preço de fechamento.

Termo	O que significa neste guia
Treinar	Ajustar o SVM com features e rótulos de observações passadas.
Validar	Medir previsões em observações posteriores e usar o resultado para escolher os hiperparâmetros.
Testar fora da amostra	Medir o desempenho no período final, que não participou da escolha dos hiperparâmetros.
Hiperparâmetros	Escolhas como kernel, C, gamma e grau. São selecionadas no desenvolvimento e mantidas na etapa final.

Datas em UTC. Desenvolvimento: 01/07/2019 a 30/12/2024. Gap de fronteira: 31/12/2024. Teste final: features de 01/01/2025 a 31/08/2026; alvos até 01/09/2026. As janelas efetivas de treinamento são menores que o histórico total.

01 | Seleção por grid search

Treinar no passado, validar depois e comparar 186 candidatos.



As três divisões reais para BTCUSDT

Divisão	Treinamento: 60 linhas	Gap	Validação: 60 linhas
1	04/05/24 a 02/07/24	03/07/24	04/07/24 a 01/09/24
2	03/07/24 a 31/08/24	01/09/24	02/09/24 a 31/10/24
3	01/09/24 a 30/10/24	31/10/24	01/11/24 a 30/12/24

O que acontece dentro de cada divisão?

1. Selecionar features e ajustar a normalização somente no treino.
2. Treinar cada um dos 186 candidatos e prever o bloco de validação.
3. Calcular o F1 de cada candidato nas 60 linhas de validação.

Na primeira divisão, o treino tinha 15 positivos e 45 negativos. Foram preservadas momentum_10, atr_14, true_range e chaikin_ad. A validação tinha 26 positivos e 34 negativos. O ajuste é feito uma vez por candidato nessa divisão; não é refeito a cada dia do bloco.

Comparação real: quatro dos 186 candidatos

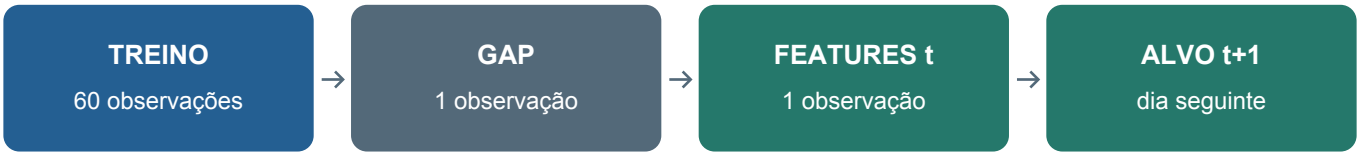
Candidato	F1 - div. 1	F1 - div. 2	F1 - div. 3	F1 médio
85 - polinomial	0,6364	0,3265	0,4865	0,4831
151 - polinomial	0,6118	0,5185	0,2581	0,4628
1 - linear	0,6479	0,2353	0,1379	0,3404
15 - RBF	0,6667	0,2703	0,0000	0,3123

Escolha: candidato 85. F1 médio = (0,636364 + 0,326531 + 0,486486) / 3 = **0,483127**, o maior entre os 186. Configuração: kernel=poly; C=1; gamma=scale; degree=3; coef0=0; class_weight=balanced.

São 558 ajustes neste caso: 186 candidatos x 3 divisões. A quantidade de divisões (3), a validação (60) e a janela de treino são configurações separadas. Para treino de 75 ou 90 linhas, continuam sendo três divisões e validação de 60 linhas.

02 | Avaliação final walk-forward

Manter os hiperparâmetros escolhidos e avançar um dia por vez.



O que acontece dentro de cada passo?

1. Separar as 60 observações de treino e deixar uma observação de gap.
2. Refazer a seleção de features e a normalização somente nesse treino.
3. Ajustar um novo SVM com os hiperparâmetros do candidato 85.
4. Usar as features de t para prever o alvo de t+1.
5. Avançar um dia e repetir o procedimento.

Os três primeiros passos reais

Treino: 60 linhas	Gap	Features t	Alvo t+1	Previsão	Real
01/11/24 a 30/12/24	31/12/24	01/01/25	02/01/25	0	1
02/11/24 a 31/12/24	01/01/25	02/01/25	03/01/25	0	1
03/11/24 a 01/01/25	02/01/25	03/01/25	04/01/25	0	0

Como ler a primeira linha?

O SVM foi ajustado com linhas de 01/11/2024 a 30/12/2024. A linha de 31/12 ficou no gap. Com as features de 01/01/2025, previu **0** para o evento de 02/01/2025. O resultado real foi **1**: houve um falso negativo.

No passo seguinte, a janela avança um dia: sai 01/11 e entra 31/12. O treinamento continua com 60 linhas.

Fixo: kernel, C, gamma, degree, coef0 e class_weight da configuração selecionada.
Atualizado em cada passo: dados de treino, features selecionadas, média e desvio-padrão da normalização e parâmetros aprendidos pelo SVM.

Como o desempenho final é medido?

As métricas finais reúnem as previsões diárias. Neste caso, foram avaliadas 608 datas. Nas mesmas datas, comparamos SVM ajustado, SVM padrão, sempre negativo e classificador baseado nas frequências das classes do treino.

Uma janela com somente uma classe é registrada sem previsão. Os quatro modelos são comparados nas mesmas datas válidas de cada combinação. O processo não busca novamente os 186 candidatos.

Como distinguir as duas etapas

Aspecto	Grid search	Avaliação final
Pergunta	Qual configuração escolher?	Como a escolha se comporta depois?
Dados de avaliação	Três blocos de validação no desenvolvimento, em 2024 neste exemplo.	Datas de features de 01/01/2025 a 31/08/2026.
Treinamento	Um ajuste por candidato em cada divisão.	Novo ajuste em cada data avaliada.
Avanço	60 observações entre divisões.	Uma observação por passo.
Hiperparâmetros	186 candidatos por moeda, alvo e janela.	Configuração selecionada mantida fixa.
Preparação das features	Aprendido em cada treino e aplicado ao bloco de validação.	Aprendido em cada treino e aplicado à observação avaliada.

Três resultados que precisam ficar separados

In sample: desempenho nos próprios dados usados para ajustar o modelo. No notebook, é a média dos três treinos do candidato selecionado, reconstruídos posteriormente.
Validação: desempenho que orientou a escolha dos hiperparâmetros.
Out of sample final: desempenho no período posterior reservado à avaliação. Nenhuma observação desse período participa da busca de hiperparâmetros.

Por que isso não é uma repetição da mesma avaliação?

Os períodos de avaliação e a frequência de atualização são diferentes. Os mesmos hiperparâmetros podem gerar fronteiras de decisão diferentes quando o treinamento muda. Dados avaliados anteriormente podem entrar em treinos posteriores quando suas informações já estão disponíveis, respeitando o gap e o horizonte do alvo. O gap mantém a última data de alvo do treino anterior à data de features avaliada.

Onde encontrar no projeto

Divisões e busca: src/tcc_crypto/modeling/splits.py; src/tcc_crypto/modeling/grid_search.py

Seleção e normalização: src/tcc_crypto/modeling/preprocessing.py

Congelamento e avaliação final: src/tcc_crypto/modeling/final_evaluation.py

Configuração do protocolo: configs/binance_daily_svm_grid_search.json

Regras da avaliação final: configs/binance_daily_svm_final_evaluation.json

Evidência numérica do exemplo: Grid search/BTCUSDT: abas Fold results, Candidate ranking e Selected configurations; teste final/BTCUSDT: dated_predictions.csv.gz.

Raízes das evidências em outputs/binance/spot/1d/: grid_search/binance_daily_svm_temporal_grid_search_v1/ e svm_final/binance_daily_svm_walk_forward_v1/. Fonte metodológica: docs/decisions/svm-temporal-grid-search-and-final-evaluation.md.

Material explicativo baseado no protocolo e nos artefatos salvos. Nenhuma coleta ou treinamento foi executado para criar este PDF. A análise é de classificação; carteiras, custos e rentabilidade pertencem às etapas financeiras.